

PROJET DE FIN DE FORMATION



La Capsule - Août 2026



Etude des facteurs de réadmission de la *patientèle* diabétique

Etats Unis 1999→2008

Projet mené conjointement par

Audric Cologne

-

Valentin Rouquier

Dossier

Valentin Rouquier



Une identité graphique réfléchie.






Table des matières

A. INTRODUCTION	5
1. Contextualisation	5
2. Le diabète, une maladie chronique	5
3. Un phénomène de société aux Etats-Unis	5
4. Dix ans d'historique d'hospitalisations	6
5. La problématique des réadmissions	7
6. Feuille de route	9
7. Note sur l'étude HbA1c	13
8. Organisation du projet	13
B. PHASE D'INITIALISATION	15
1. Importation des données initiales vers Google Sheets	15
2. Paramétrage d'Airbyte	15
3. Paramétrage de Google BigQuery	16
4. Exportation des données vers BigQuery	17
C. PHASE DE TRANSFORMATION/NETTOYAGE	18
1. Modèle logique de données	18
2. Paramétrage de dbt en local	21
3. Staging	22
4. Intermediate	23
5. Marts	24
6. Macros	25
D. PHASE D'EXPLORATION	26
1. Exploration des données	26
2. Premières observations	26



E. ORCHESTRATION DU PIPELINE	28
F. MACHINE LEARNING	29
1. Etablissement et tests des modèles de prédiction	29
2. Conclusions	29
G. VISUALISATION	31
1. Création du dashboard sous Microsoft PowerBI	31
2. Modélisation - Power Query & DAX	34
H. CONCLUSION	54
1. Enseignements et recommandations	54
2. Gestion du projet, limites et perspectives d'améliorations	55
3. Remerciements	56
Annexe — Récapitulatif	57
A. fact_hospitalisations	57
B. dim_patients	59
C. dim_types_admissions	59
D. dim_sorties	60
E. dim_sources_admissions	60
F. dim_specialites_medicales	61
G. dim_icd9	61
H. jonction_diagnostiques (table de liaison)	61
I. Variable cible — logique de construction	62
J. Features retenues pour le modèle prédictif final (9 sur 115)	62



A. INTRODUCTION

1. Contextualisation

La réadmission hospitalière est un problème coûteux et suivi de près dans les systèmes de santé. Aux États-Unis, les hôpitaux sont pénalisés financièrement¹ lorsque leur taux de réadmission dépasse un seuil attendu, car une réadmission rapide signale souvent une prise en charge incomplète lors du premier séjour.

Pour les patients diabétiques, dont la maladie est chronique et complexe à gérer en milieu hospitalier, l'enjeu est particulièrement fort et donc propice à étude.

Nous nous voyons donc confier dans cette optique la mission fictive suivante : une direction hospitalière souhaite identifier, dès la sortie, les patients diabétiques les plus à risque d'être réadmis sous trente jours, afin de leur proposer un suivi renforcé. Sont transmis dix ans d'historique de séjours avec deux objectifs clés :

- Comprendre ce qui caractérise les patients réadmis
- Construire un outil de prédiction utilisable.

2. Le diabète, une maladie chronique

Le diabète est une maladie chronique caractérisée par un taux de sucre (glucose) trop élevé dans le sang, appelé hyperglycémie.

Il existe principalement deux formes :

- **Diabète de type 1** : où le corps ne produit plus d'insuline (souvent diagnostiqué chez l'enfant ou le jeune adulte)
- **Diabète de type 2** : la forme la plus répandue, où l'organisme devient résistant à l'insuline ou n'en produit plus suffisamment, généralement lié à l'âge, au surpoids ou à la sédentarité.

Non traité, le diabète peut entraîner des complications sérieuses à long terme : atteintes cardiovasculaires, rénales, oculaires ou nerveuses. Sa prise en charge repose sur une surveillance régulière de la glycémie, une alimentation adaptée, de l'activité physique et, selon les cas, un traitement par insuline ou médicaments.

3. Un phénomène de société aux Etats-Unis

La période étudiée est synonyme de forte progression du diabète aux États-Unis : la prévalence croît alors à un rythme annuel d'environ +4 % chez les populations

¹ Medicare/CMS est à l'origine de ces pénalités financières, en cas de pénalité, seule une partie du séjour est remboursée à l'hôpital concerné.



les plus âgées², portée par le vieillissement de la population, la hausse de l'obésité et l'amélioration du dépistage. En 2000, près de 11 millions d'américains sont touchés et le diabète est listé à la 6ème place des causes de décès.

Depuis, la tendance s'est poursuivie : en 2023, on estime que 40,1 millions d'Américains vivent avec un diabète diagnostiqué ou non (12 % de la population). La mortalité liée au diabète de type 2 a elle aussi plus que doublé sur la période 1999-2023³.

Le sujet de la réadmission hospitalière, au cœur de ce projet, reste donc un enjeu de santé publique toujours aussi pertinent aujourd'hui qu'il ne l'était lorsque les données ont été collectées.

4. Dix ans d'historique d'hospitalisations

Nous travaillerons sur le jeu de données Diabetes 130-US Hospitals, issu du UCI Machine Learning Repository. Il rassemble un peu plus de **cent mille séjours** hospitaliers de patients diabétiques, collectés sur dix ans entre **1999** et **2008** dans cent trente établissements américains. Chaque ligne décrit un séjour, avec une **cinquantaine de variables** : démographie du patient, type d'admission, durée du séjour, diagnostics codés, résultats de laboratoire, médicaments administrés, mode de sortie, et le devenir du patient après sa sortie.

La variable cible est la colonne **readmitted**, qui indique si le patient a été réadmis, et si oui dans quel délai⁴.

Le téléchargement fournit deux fichiers:

- **diabetic_data.csv**, contient les séjours.
- **IDs_mapping.csv**, est une table de correspondance qui traduit certains identifiants numériques en libellés lisibles, par exemple le type d'admission ou le mode de sortie.

Le jeu de données est disponible [ici](#).

Sa source, **Strack et al., Diabetes 130-US Hospitals for Years 1999-2008, UCI Machine Learning Repository, 2014.**

² CDC — National Diabetes Statistics Report (cdc.gov/diabetes/php/data-research)

³ Type 2 Diabetes Mellitus–Related Mortality in the United States, 1999-2023, NCBI/PMC

⁴ Medicare/CMS est également à l'origine de la fenêtre choisie des 30 jours, un compromis permettant de capter les réadmissions évitables liées aux soins et assez long pour ne pas exclure les complications qui mettent quelques semaines à se déclarer.



Ce jeu de données a été entièrement *anonymisé* afin de rendre impossible l'identification des patients par un tiers.

S'est toutefois posé la question de la sécurité et du respect des RGPD, question d'autant plus essentielle qu'il s'agit de données médicales, donc sensibles, et nous avons donc ci après posé l'hypothèse d'un traitement en conditions réelles, sans *anonymisation* préalable.

Dans un vrai contexte hospitalier et donc soumis au RGPD, plusieurs colonnes seraient qualifiées de données personnelles ou sensibles :

- **Données de santé** : diagnostics (`diag_1/2/3` - codes ICD9), résultats de labo, médicaments/posologie, spécialité médicale, type d'admission, durée de séjour.
- **Données pouvant rendre possible l'identification** : âge (même par tranche), genre, ethnie; et dans le cas où ces données seraient horodatées : dates d'admission, sortie.. En croisant ces données, l'identification des patients devient un risque plausible.
- **Identifiants techniques** : `patient_nbr` et `encouter_id` sont des identifiants directs ; même *pseudonymisés*, ils restent une donnée personnelle selon le RGPD et la ré-identification reste possible.

Concernant la conservation des données, le RGPD nous imposerait les ajustements suivants :

- ne conserver que les colonnes utiles au cas d'usage, notre étude et notre modèle de prédiction; c'est également - au delà de l'absence de données dans de nombreux cas, ce qui a notamment motivé la non conservation des colonnes `weight` et `payer_code` par exemple.
- Définir une durée limitée de conservation, à l'étape du staging par exemple.
- Limiter l'accès aux données via les différents paramètres mis à notre disposition dans les outils utilisés.

C'est justement dans cet esprit que nous "décomposer" les différents accès à BigQuery via les permissions accordées à chaque services accounts, voir **B-3**.

5. La problématique des réadmissions

Une **réadmission** (un patient ré-hospitalisé peu de temps après sa sortie, généralement dans les 30 jours) est considérée comme un signal d'alerte : dans



une part significative des cas, elle traduit une sortie mal préparée, un suivi post-hospitalisation insuffisant, ou une prise en charge initiale incomplète — donc un événement potentiellement évitable plutôt qu'une simple fatalité médicale.

- **Impact financier**

Le coût est massif à l'échelle du système de santé américain : les réadmissions évitables sous 30 jours génèrent plus de 26 milliards de dollars de coûts annuels et touchent environ 3,8 millions de bénéficiaires Medicare. Sur la seule population Medicare, environ 20 % des bénéficiaires sont réadmis dans les 30 jours, pour une charge financière annuelle d'environ 17,4 milliards de dollars⁵.

Face à ce constat, les autorités américaines ont mis en place un mécanisme punitif directement lié à la performance des hôpitaux : le **Hospital Readmissions Reduction Program (HRRP)**, lancé en 2013 dans le cadre de l'Affordable Care Act. Ce programme applique des pénalités de 1 % à 3 % sur les remboursements Medicare aux hôpitaux dont le taux de réadmission dépasse la moyenne nationale ajustée au risque, pour un ensemble de pathologies ciblées. 93 % des hôpitaux évalués ont été pénalisés au moins une fois en 10 ans de programme, et 1 288 établissements l'ont été chaque année depuis 2013⁶.

- **Impact opérationnel**

Au-delà de la pénalité financière directe, une réadmission mobilise à nouveau lits, personnel soignant et plateau technique pour un même patient — une charge que l'hôpital aurait pu éviter avec une meilleure anticipation. Le retour sur investissement d'une réduction des réadmissions est d'ailleurs documenté : un hôpital évite en moyenne 8 000 à 17 000 dollars de manque à gagner par réadmission évitée selon la pathologie, un gain net qui dépasse largement le coût de mise en place des actions de prévention⁷.

C'est précisément ce contexte qui justifie l'intérêt opérationnel de notre étude : en identifiant en amont les patients à haut risque de réadmission et les leviers d'action associés, un hôpital peut cibler ses efforts de suivi post-sortie là où ils ont le plus d'impact financier et humain.

⁵ arXiv — cadre explicable de prédiction de réadmission (2026) et CDC/CMS — Hospital Readmissions Reduction Program (HRRP)

⁶ KFF — "10 Years of Hospital Readmissions Penalties"

⁷ PMC — "A Reduction in Readmissions Results in Net Savings for Most Hospitals"



6. Feuille de route

Grâce aux informations récoltées et présentées précédemment nous avons pu établir une feuille de route de notre future étude en définissant en premier lieu la question à laquelle notre étude doit répondre, à savoir :

Quels sont les facteurs actionnables pouvant limiter les ré-admission de patients atteints du diabète sous 30 jours ?

Pour cela nous avons défini plusieurs KPI à exploiter pour nous aider à y répondre :

- **Taux de réadmission < 30j/>30j**
→ variable cible
- **Profil type d'un diabétique hospitalisé : ethnique, âge, sexe, résultat du test A1c**
→ identifier un possible pattern sur la population touchée par le diabète
- **Prise en charge type d'un diabétique : type admission, durée hospitalisation, nombre de médicaments administrés**
→ identifier un possible pattern sur la prise en charge du diabète
- **Nombre moyen de médicaments utilisés/testés durant le parcours médical**
→ plusieurs pistes :
 - faire le lien coût stratosphérique des médicaments aux Etats-Unis
 - mettre en avant la notion de temps : le parcours est long, les test/essais de médicaments efficaces est chronophage
- **Taux de diabète correctement identifiés au 1er diagnostic**
→ souligne l'importance d'une prise en charge au plus tôt
- **Features hautement corrélés à une réadmission**
→ déterminées en fonction des résultats du machine learning

D'un point de vue technique, nous avons ensuite listé les outils utilisés et défini notre pipeline :

A. Importation des .csv du jeu de données original dans Google Sheets, soit 4 tables :

- `diabetes_dataset` ← données raw extraites de `diabetic_data.csv`



- types_admissions
- sorties
- sources_admissions





← données raw extraites de `IDs_mapping.csv`

- B. Exportation des données Google Sheet vers Google BigQuery via l'utilisation d'Airbyte
- C. Exploration des données grâce à Google Collab
- D. Nettoyage et Transformation via dbt installé en local⁸
- E. Machine Learning grâce à Google Collab
- F. Création d'un dashboard sous Microsoft PowerBI
- G. Orchestration du flow suivant avec Airflow

⁸ dbt Cloud étant limité, nous avons favorisé une version gratuite et donc locale.



- the PIPELINE -





Plusieurs problématiques ont été identifiées et traitées avant de débiter :

→ **absence de temporalité**

Notre dataset original ne contient aucune donnée horodatée, notre étude ne contiendra donc aucune dimension temporelle.

→ **réadmissions du même patient**

Point de vigilance ici : la table principale contient plusieurs entrées pour le même patient. → Cela peut poser des problèmes au niveau de l'indépendance des données, surtout lorsqu'il faudra créer des modèles.

La donnée "Tranche-age" enregistrée pour chaque hospitalisation peut être amenée à varier, un patient pouvant naturellement changer de tranche entre deux hospitalisations → cette donnée ne pourra donc pas être rattachée à un patient unique.

→ **le décès**

Un patient qui décède ne peut pas être réadmis, il faut les compter et les retirer de notre analyse.

→ **absence de variable sévérité ou types**

Aucun indice quant au type de diabète diagnostiqué n'est présent dans le dataset, ni d'indice sur la sévérité de la maladie quand bien même celle-ci n'est pas corrélée au type de diabète diagnostiqué. → la caractérisation type 1/type 2 de la maladie ne pourra pas être exploitée.

Enfin concernant notre variable cible, puisque nous nous intéressons principalement aux facteurs qui conduisent à une réadmission précoce, nous avons défini l'attribut de réadmission (résultat) comme ayant deux valeurs:

- «**réadmis**» si le patient a été réadmis dans les 30 jours suivant la sortie, traduit en binaire par la valeur **1**.
- «**autrement**», qui couvre à la fois la réadmission après 30 jours et l'absence de réadmission, traduit en binaire par la valeur **0**.

→ **absence de la variable weight**

97% de la colonne weight est vide. En effet, avant l'American Reinvestment and Recovery Act, la donnée "poids" du patient n'était pas rapportée de manière systématique. Cette colonne ne sera pas conservée.



→ colonne payer_code

52% de la colonne payer_code, correspondant au régime d'assurance du patient, est vide. Cette colonne ne sera donc pas conservée en raison de l'absence d'une grande proportion des données. Toutefois rétrospectivement, cela nous aurait permis de développer le volet économique de notre étude, les mutuelles et le coût des soins étant un vrai sujet de fond aux Etats Unis.

7. Note sur l'étude HbA1c

Une première étude princeps sur notre dataset (Strack et al., 130 hôpitaux américains, 1999-2008) a spécifiquement mis en évidence le test HbA1c (mesure de l'hémoglobine glyquée) comme un facteur prédominant dans la prédiction de la réadmission des patients diabétiques : sa réalisation et son résultat sont fortement associés à un risque de réadmission réduit.

Ce lien étant déjà solidement établi et documenté par la littérature source, nous avons fait le choix délibéré d'écarter cette variable de notre analyse, afin de concentrer nos efforts sur l'exploration d'autres facteurs de risque moins étudiés — antécédents de visites hospitalières, durée de séjour, spécialité médicale, diagnostics associés — susceptibles d'apporter des leviers d'action complémentaires et inédits pour la prévention des réadmissions.

8. Organisation du projet

Nous avons fait le choix de travailler en parallèle sur la plupart des tâches afin de mettre en pratique le maximum de connaissances nouvellement acquises et avons mis ensuite nos travaux en commun afin d'en tirer le meilleur.

Coté outils, nous avons partagé un Google Docs commun pour nos différentes notes, un dossier sous Google Drive pour stocker l'intégralité de nos fichiers et un repo Git pour la mise en commun de nos travaux sur dbt (voir **C-2**), le tout avec un Trello pour le suivi.



JOUR 1	Etude des consignes, du dataset, Recherche d'informations, contexte, chiffres, Etablissement de nos KPI, Features engineering
JOUR 2	Mise en place d'Airbyte, import des csv sur GSheet, Paramétrage de BigQuery, Mise en place du dbt local et commun via GitHub
JOUR 3	Mise en place et test sur le dbt collaboratif avec définition des branches git nominales et dataset bigq nominaux Début du codage staging, int, marts sur dbt Etude des données sur BigQuery pour déceler les anomalies et décider de leur traitement
JOUR 4	Continuation du codage dbt, Merge dbt Exploration des données sur Google Collab
JOUR 5	Mise en commun de nos exploration de données, Début du Machine Learning
JOUR 6	Continuation du machine learning, clustering, modèles et mise en commun. Début du Dashboard PowerBI
JOUR 7	Continuation du dashboard PBI, Codage du DAG et paramétrage AirFlow
JOUR 8	Continuation du dashboard PBI, Tests Airflow avec tentative d'installer Airbyte en local
JOUR 9	Dernières finalisations, Début de la rédaction du dossier
JOUR 10	Finalisation de la présentation du Dashboard, Rédaction du dossier




B. PHASE D'INITIALISATION

1. Importation des données initiales vers **Google Sheets**

La totalité de nos données originales compilées dans le csv téléchargé `diabetic_data.csv` a été importé dans un Google Sheet dédié nommé [Dataset_Original_Diabete](#).

Aucune transformation préalable n'a été effectuée dans ce fichier, seul un formatage Tableau a été appliqué via **Format → Convert to table**.

La même manipulation a été effectuée pour les 3 autres tables de mapping :



Là encore, aucune transformation préalable n'a été effectuée dans ces fichiers, seul un formatage Tableau a été appliqué via **Format → Convert to table**.

Pour nos futures introspections, deux tables supplémentaires ont été créées :

- [Diagnostic_Codes_Simple](#) : compile les codes diagnostiques ICD9⁹, leur description et catégories
- [Medical_Speciality_Mapping](#) : compile la spécialité médicale (colonne `medical_speciality` du dataset d'origine) et une description.

2. Paramétrage d'**Airbyte**

Pour ingérer les données nécessaires à ce projet, nous avons choisi Airbyte, un outil d'intégration de données open-source qui automatise l'extraction et le chargement de données (ELT) depuis des sources variées vers un entrepôt de données cible.

⁹ L'ICD-9 (International Classification of Diseases, 9e révision) est un système de classification médicale standardisé, développé par l'Organisation mondiale de la santé, qui attribue un code numérique unique à chaque diagnostic, maladie ou procédure médicale afin d'en permettre l'enregistrement, le suivi statistique et l'échange normalisé entre systèmes de santé.



Concrètement, Airbyte se charge de récupérer les données à intervalle régulier depuis leurs emplacements d'origine et de les déposer, sans transformation, dans notre data warehouse — laissant ensuite dbt gérer la couche de transformation en aval.

Dans notre cas, nous avons configuré :

- des **sources** Google Sheets (où sont stockés nos données raw - voir 1.)

connectées à

- une **destination** BigQuery, où les données brutes sont chargées dans des tables dédiées avant d'être reprises par nos modèles dbt (staging, intermédiaire, marts).

Ce choix nous a permis d'automatiser un pipeline auparavant manuel, de garantir une synchronisation régulière entre les sources et l'entrepôt, et de nous appuyer sur une architecture ELT standard, découplant clairement l'ingestion (Airbyte) de la transformation (dbt).

3. Paramétrage de Google BigQuery

Pour structurer notre infrastructure de données, nous avons commencé par créer un projet Google Cloud dédié (**projectdiabeteus**), servant d'espace isolé pour l'ensemble du pipeline.

À l'intérieur de ce projet, nous avons mis en place des datasets de réception distincts, destinés à accueillir des données bien définies :

- **projectdiabeteus_Dataset_Original_Diabete** : destiné à réceptionner l'ensemble des tables importées dans Google Sheets via Airbyte
- **dbt_audric** et **dbt_valentin** : destinées à réceptionner nos travaux respectifs sur dbt (voir ci après)
- **dbt_shared** : destiné à réceptionner les tables finales, transformées et nettoyées

Côté sécurité et accès, nous avons créé plusieurs comptes de service (service accounts) dédiés, chacun disposant de permissions spécifiques selon son usage :



- un compte pour Airbyte avec les rôles suivants :
 - **BigQuery Data Editor** : Permet de créer, modifier et supprimer des datasets et tables.
 - **BigQuery User** : Rôle "de base" combinant l'exécution de jobs et la création de datasets.
- un compte pour le déploiement dbt (mêmes rôles que le compte airbyte)
- un compte pour Power BI avec les rôles suivants :
 - **BigQuery Data Viewer** : Accès en lecture seule aux données sans possibilité de les modifier.
 - **BigQuery Job User** : Autorise l'exécution de jobs dans le projet mais sans accès direct aux données.
 - **Service Usage Consumer** : Autorise un utilisateur ou un compte de service à consommer les API et services activés d'un projet Google Cloud
- Et deux comptes pour chacun d'entre nous, avec le rôle suivant :
 - **Owner** : Rôle donnant un contrôle total sur l'ensemble du projet Google Cloud.

Pour chacun, une clé JSON a été générée et utilisée comme identifiant d'authentification dans l'outil correspondant, sans jamais exposer de compte utilisateur personnel.

Cette approche s'appuie sur la gestion IAM (Identity and Access Management) de Google Cloud, qui permet d'attribuer à chaque compte de service uniquement les rôles nécessaires à sa fonction — principe du moindre privilège — limitant ainsi les risques liés à des accès trop larges ou non maîtrisés sur le projet.


4. Exportation des données vers BigQuery

Une fois l'ensemble des outils paramétrés, nous avons pu activer la connexion **Google Sheets** → **BigQuery** sur Airbyte et lancer l'exportation de l'ensemble de nos tables vers le dataset `projectdiabeteus_Dataset_Original_Diabete`.




C. PHASE DE TRANSFORMATION/NETTOYAGE

1. Modèle logique de données



Pour notre étude, nous avons établi un modèle en **étoile** : une table de faits centrale, entourée de tables de dimensions qui la décrivent.



La table de faits : fact_hospitalisations

C'est le cœur du modèle, avec une granularité correspondante à une ligne = une hospitalisation. Elle concentre :

- Une clé primaire : `hospitalisation_id`
- Les clés étrangères vers toutes les dimensions :
 - `patient_id`,
 - `type_admission_id`,
 - `sortie_id`,
 - `source_admission_id`,
 - `diag_id`,
 - `specialite_id`
- Les mesures numériques exploitables :
 - `n_test_lab`,
 - `n_procedure`,
 - `n_medicament`,



- `n_visite_externe`,
 - `n_visite_urgence`,
 - `n_visite_hospitalisation`,
 - `n_diag`,
 - `n_changement_posologie`,
 - `duree`
-
- Les indicateurs binaires/catégoriels utiles au filtrage :
 - `readmis`,
 - `insulin`,
 - `tranche_age`

C'est cette table qui alimente nos métriques (taux de réadmission, durée moyenne de séjour, etc.).

Les tables de dimensions

Chaque dimension apporte du contexte descriptif à la table de faits :

- `dim_patients` : caractéristiques démographiques du patient (ethnie, genre). Une ligne par patient, réutilisable si un même patient a plusieurs hospitalisations.
- `dim_types_admissions` : nature de l'admission (urgence, élective, etc.) — décrit `type_admission_id`.
- `dim_sorties` : mode de sortie du patient (domicile, transfert, décès...) — décrit `sortie_id`.
- `dim_sources_admissions` : origine de l'admission (référence médecin, transfert d'un autre établissement...) — décrit `source_admission_id`.
- `dim_icd9` : nomenclature des diagnostics médicaux (code ICD9, description, catégorie) — table de référence indépendante.
- `dim_specialites_medicales` : spécialité médicale du médecin consultant — décrit `specialite_id`.

Le cas particulier : **diagnostics** → **table de jonction**

Petite ex-croissance de notre modèle en étoile, la table **diagnostics**.

Une même hospitalisation peut être associée à plusieurs diagnostics, et un même diagnostic peut concerner plusieurs hospitalisations. Cette table fait le pont entre `fact_hospitalisations` et `dim_icd9` sans dupliquer les mesures de la table de faits.




2. Paramétrage de dbt en local

Pour contrer les limitations de dbt cloud, nous avons préféré l'utilisation de sa version locale que nous avons donc installé sur nos postes respectifs.

Nous avons ensuite mis en place un workflow dbt collaboratif basé sur Git et un repo dédié, pour que nous puissions travailler de manière indépendante.

Concrètement, chacun de nos postes respectifs a été configuré en local avec dbt et Git installés, et chacun a donc utilisé son propre dataset de développement sur BigQuery – `dbt_valentin` et `dbt_audric` précédemment détaillés. Cela nous a permis de tester et d'itérer sur nos modèles sans jamais toucher aux données de prod.





Tout notre travail transite ensuite par un repo GitHub central, qui fait office d'historique partagé : on travaille sur des branches, et on ouvre des Pull Requests pour faire relire et valider les changements avant de les intégrer.

Initialement nous avions prévu d'automatiser cette phase avec déclenchement automatique d'un dbt build via GitHub Actions, mais nous avons finalement opté pour un déclenchement manuel afin de maîtriser au mieux le processus.

Une fois la PR validée et mergée sur la branche main, c'est seulement à ce moment-là que les transformations sont déployées vers l'environnement de production, dans le dataset `dbt_shared` sur BigQuery.

→ IMPORTANT

Nous avons fait le choix de travailler chacun les points qui suivent afin de consolider nos connaissances acquises, continuer à s'entraîner et ainsi progresser.

Est présenté ici mon travail personnel sur **dbt** dont la résultante est identique* aux travaux menés en parallèle par mon collaborateur.

Concernant l'exploration des données et l'élaboration du modèle de prédiction, le résultat présenté ci après résulte de la mise en commun de nos travaux respectifs.

3. Staging

La couche staging fait le lien entre la donnée brute chargée via Airbyte (source `raw_diabetic_data`) et le reste du pipeline. Son objectif ?

renommer, typer et nettoyer.

→ `stg_diabetic_data`

Il part de la table brute..

- Typage sécurisé : tous les identifiants et compteurs (`hospitalisation_id`, `patient_id`, durée, nombre de tests/procédures/médicaments, visites antérieures...) sont castés en **INT64** via `safe_cast`, qui renvoie **NULL** plutôt que de faire planter le run en cas de valeur invalide.
- Correction de deux incohérences connues dans la source : les types d'admission 5, 6, 8 sont fusionnés sous 5 et le 7 remappé en 6 ; la source



d'admission 15 est fusionnée avec 9 (même libellé dans la table de référence, mais deux ids différents à l'origine).

- Normalisation générique des colonnes texte : plutôt que d'écrire une transformation par colonne, le modèle boucle en Jinja sur une liste `colonnes_texte` (âge, spécialité médicale, les ~20 médicaments, les diagnostics, résultats de labo, statut de réadmission...) et leur applique une macro commune, `normalisation_outcasts`. Ainsi si la règle de nettoyage change, elle change à un seul endroit pour toutes les colonnes concernées.

→ Les quatre modèles de dimension

- `stg_icd9` : renomme simplement les codes diagnostiques ICD-9, leur description et leur catégorie.
- `stg_sorties` et `stg_sources_admissions` : suivent le même pattern — cast de l'id en **INT64**, renommage du libellé. Pas de logique de fusion ici, contrairement aux types d'admission.
- `stg_types_admissions` : applique la même règle de fusion des codes que `stg_diabetic_data` (5/6/8 → 5, 7 → 6), avec un distinct pour éviter les doublons issus du remapping, et nettoie les libellés ambigus ('Not Available', 'NULL', 'Not Mapped') en un 'Unknown' unique.
- `stg_specialites_medicales` : seul modèle à générer une clé artificielle, `specialite_id`, via `ROW_NUMBER() OVER (ORDER BY original_speciality)`, faute d'identifiant natif dans la source.

Les fichiers originaux sont consultables [ici](#).

4. Intermediate

Le modèle part de deux sources : `stg_diabetic_data` (la table centrale du staging) et `stg_specialites_medicales`, qu'il croise via un `LEFT JOIN` sur le libellé de la spécialité (`specialite_medecin = specialite`). L'objectif de cette jointure est simple : remplacer un texte libre par une clé numérique propre, `specialite_id`, exploitable ensuite comme clé étrangère dans la table de faits.

Cinq transformations métier ont ensuite lieu dans ce modèle :



- **Traduction de la colonne `insulin`**¹⁰ : Les valeurs `Up/Down/Steady/No` sont traduites en français (augmentation/reduction/stable/Non) — un choix de lisibilité puisque reprise dans Power BI.
- **Calcul de `n_changement_posologie`** : pour chacun des ~21 médicaments, on teste si sa valeur est `Up` ou `Down` (donc changement, à l'exclusion de `Steady` qui signifie "prescrit mais stable"), et on somme le tout.
- **Construction de la cible `readmis`** : La colonne `readmitted` (`<30`, `>30`, `NO`) est transformée en booléen strict : `true` si `<30`, `false` si `>30` ou `NO`.
- **Résolution des incohérences patient** : suite à l'étude des données raw nous avons également décelés deux problèmes concernant les données `ethnie` et `genre` des patients : certains avaient deux ou plusieurs genres enregistrés, idem pour `ethnie`. Dans ce cas, le modèle retombe alors sur '?' plutôt que d'en choisir un arbitrairement — une manière de représenter l'incertitude plutôt que de la masquer.

Le fichier original est consultable [ici](#).

5. Marts

Ce volet permet la construction du modèle analytique final, utilisé plus tard dans l'établissement de notre modèle de prédiction puis dans PowerBI.

→ Les dimensions

`dim_icd9`, `dim_sorties`, `dim_sources_admissions`, `dim_specialites_medicales` et `dim_types_admissions` sont volontairement simplistes puisqu'on reprends tel quelles les tables établies dans l'étape précédente du staging et on force leur matérialisation dans BigQuery.

Seule exception : `dim_patients`, que nous construisons via un `SELECT DISTINCT` sur `patient_id`, `ethnie`, `genre` depuis `stg_diabetic_data`. Dans cette dernière, un `patient_id` peut avoir plusieurs hospitalisations au compteur, il est donc important d'isoler les valeurs `patient_id` uniques dans cette table de dimension pour éviter les doublons.

→ `fact_hospitalisations` — la table de faits

La table centrale à notre étude est construite ici post étape intermédiaire.

Cette table centralise une ligne par hospitalisation, avec toutes les clés étrangères vers les dimensions (`patient`, `type d'admission`, `sortie`, `spécialité`, `source d'admission`) et les mesures numériques (`durée`, `nombre de tests/procédures`).

¹⁰ Ce paramètre n'a pas été retenu dans la version finale sur `dbt_shared` par soucis de cohérence, les autres colonnes n'ayant pas été traduites.



médicaments, visites antérieures, changements de traitement) plus la variable cible readmis.

→ `jonction_diagnostiques` — la table de liaison

Un patient peut avoir jusqu'à 3 diagnostics par hospitalisation (`diag_1`, `diag_2`, `diag_3`), et un même diagnostic peut concerner plusieurs hospitalisations. Ce modèle résout ça par un unpivot classique — trois `SELECT` mis bout à bout en `UNION ALL`, un par colonne de diagnostic — pour obtenir une ligne par couple (hospitalisation, diagnostic), en excluant les diagnostics nuls.

C'est cette table qui permet ensuite de joindre `fact_hospitalisations` à `dim_icd9`.

Les fichiers originaux sont consultables [ici](#).

6. Macros

Afin d'alléger le code précédent, une macro a été créée, sous forme d'une petite fonction de nettoyage/normalisation de données : elle transforme tous les cas "pas de valeur exploitable" (NULL réel, chaîne vide, ou texte "NULL" mal importé) en un marqueur unique '?' :

```
{% macro normalisation_outcasts(column_name) %}  
  case  
1.....when {{ column_name }} is null then '?'  
2.....when trim({{ column_name }}) = '' then '?'  
3.....when upper(trim({{ column_name }})) = 'NULL' then '?'  
4.....else {{ column_name }}  
  end  
{% endmacro %}
```

Appliquée sur la totalité de la colonne `column_name`,

- Ligne 1 : si une valeur est nulle au sens SQL - absence de valeur - on remplace par "?",
- Ligne 2 : si la valeur est une chaîne vide ou ne contient que des espaces, on remplace par "?",
- Ligne 3 : si la valeur est une chaîne de caractères "null" (upper gérant les différentes casses possibles, trim les espaces parasites)
- Ligne 4 : si aucune des conditions précédentes n'est remplie, on conserve la valeur d'origine.

Le fichier original est consultable [ici](#).



D. PHASE D'EXPLORATION

1. Exploration des données

L'exploration des données est accessible [ici](#).

2. Premières observations

- Un changement de posologie de l'insuline semble associé à une probabilité de réadmission plus élevée.
- Le type de sortie pourrait aussi être corrélé avec la réadmission.
- Les catégories semblent assez peu liées à la réadmission, notamment l'ethnie et le genre.

Quelques étrangetés supplémentaires ont été mises en évidence :

- Le nombre exagérément élevé de médicaments prescrits ou de tests en laboratoire effectués durant la visite

→ Nous avons imposé des limites à 50 et 100 respectivement

- Le nombre de visite médicale (externe, urgence, hôpital) 1 an avant l'hospitalisation est 0 dans la quasi-totalité des cas mais peut être exagérément élevé

→ Nous avons calculé un score compris entre 0 et 10 pour modéliser ces visites, donnant un poids important au nombre de visites à l'hôpital car fortement corrélé avec la réadmission.

- Le nombre de diagnostics effectués durant la visite, avec un pic à 9 et presque aucune valeur supérieure à 9, ce qui est vraisemblablement lié à une limitation humaine/informatique

→ Nous avons imposé une limite à 9

La plupart des features, principalement catégorielles, ne semblent pas ou peu corrélées avec la réadmission. Les corrélations numériques observées sont toutes positives.



Le score de visites antérieures est le meilleur prédicateur individuel. Un patient avec plusieurs visites médicales l'année précédente est clairement « consommateur de soins » et plus **fragile**.

Le changement de posologie signale des ajustements difficiles ou des complications pendant le séjour.

→ Il risque d'être difficile pour un modèle de prédire la réadmission à partir de ces features.



E. ORCHESTRATION DU PIPELINE

Notre objectif premier était d'orchestrer l'ensemble de notre pipeline présenté précédemment à l'aide d'Airflow. Cependant les choses ne se sont pas passées comme prévues.

Comme pour nos travaux sur dbt nous avons chacun travaillé à l'établissement d'un DAG sur le modèle d'orchestration suivant, le tout en plusieurs étapes :

`sync_airbyte >> dbt_run >> dbt_test`

La `sync_airbyte` étant mise en place grâce à `AirbyteTriggerSyncOperator` et les deux dbt via un `BashOperator`.

Malheureusement en cours de projet, nos accès à airbyte ont été limités, nos deux comptes manquant de crédits. Solution de repli ? Installer en local une version d'airbyte, toutefois sans succès.

Nous n'avons donc pas réellement pu mettre en action l'orchestration de notre pipeline.

Une version du DAG est consultable [ici](#).



F. MACHINE LEARNING

1. Etablissement et tests des modèles de prédiction

Notre étude de machine Learning est accessible [ici](#).

2. Conclusions

- Une très faible proportion de *features* (9) permet de construire des modèles aussi performants que ceux utilisant tous les *features* (115).

Ces *features* sont :

- 'categorie_diag_1_Neoplasms/Cancer',
 - 'categorie_diag_2_Neoplasms/Cancer',
 - 'categorie_diag_3_Follow-up/Rehabilitation',
 - 'categorie_sortie_Care Facility',
 - 'categorie_sortie_Hospital',
 - 'categorie_sortie_Home',
 - 'categorie_specialite_Oncology',
 - 'n_diag_max_9',
 - 'score_visite'
- Seule la catégorie de sortie Home est associée à une non-réadmission.
 - La plupart de ces *features* sont plus des conséquences que des causes :
 - Si un patient globalement en bonne santé est hospitalisé pour une raison mineure, il engendrera forcément peu de diagnostics lors de sa visite, aura un score de visite faible puisque globalement en bonne santé et sera vraisemblablement libre de rentrer chez lui à la fin de l'hospitalisation.
 - Si un patient est hospitalisé pour des symptômes liés au cancer, il sera probablement suivi par un oncologue, aura des diagnostics de cancers et sera vraisemblablement très suivi sans possibilité de rentrer chez lui
 - Si un patient chronique, avec de lourds symptômes et complications est hospitalisé, il aura un score de visite et un nombre de diagnostics très élevé, et sera forcément plus probablement réadmis.

Que pouvons nous faire avec nos données ?

Les performances des modèles prédictifs sont décevantes. Le rappel de 58% avec 17% de précision signifie qu'on détecte bien les réadmissions potentielles, mais



qu'on génère beaucoup de faux positifs ce qui implique une surcharge si on applique un suivi intensif à tous les patients signalés (1/6).

Cependant, certains groupes sont mieux prédits que les autres, notamment les 20-30 ans pour lequel le modèle est bien adapté et très performant, malgré le fait que cette catégorie représente peu d'hospitalisation. Cela est probablement dû à des réadmissions homogènes et bien capturées par le modèle dans ce groupe (vraisemblablement des cancers).

Nous pouvons alors conclure que la réadmission est un événement relativement rare et multi-factoriel, pouvant aussi être déterminé par des facteurs socioéconomiques, comportementaux et environnementaux non observés.




G. VISUALISATION


1. Création du dashboard sous Microsoft PowerBI

La création de notre dashboard sous Microsoft PowerBI a d'abord nécessité la création d'une connexion avec Google BigQuery et notre dataset principal précédemment transformé et nettoyé grâce à notre flow dbt; le tout a été paramétré grâce à un service account dédié et une clé json spécialement générée dans ce but.

Une fois les données importées, les liaisons one-to-many ont été recréées:



Pour le volet Machine Learning du dashboard (slides 6 et 7), les résultats obtenus dans notre étude ont également été importés dans BigQuery sur le même principe :



4 tables:

- `RFC_confusion_matrix` : résultats de notre matrice de confusion
- `RFC_features_importance` : listing des features et de leur % d'importance
- `RFC_metrics` : compilation des scores f1, precision, recall et roc_auc
- `RFC_ROC` : compilation des true et false positive rates+threshold de la courbe ROC

Seules les 3 premières seront utilisées dans notre futur dashboard.

→ Ossature du dashboard :

- **[SLIDE 1]** Introduction avec mise en avant - à travers quelques statistiques économiques et centrés sur les hospitalisations - du fardeau économique représenté par le diabète aux USA.
- **[SLIDE 2]** Axe 1 - diabète passé, présent, futur
 - Accroche : une pathologie du présent, un défi pour l'avenir.
 - présentation de la pathologie
 - population touchée via patient type
 - 11 M d'américains diabétiques (4%) en 2000 vs 29.1M en 2023 (~8%)
 - KPI : nombre de visite moyenne pré hospitalisation, durée d'une admission/séjour, nombre de médicaments moyen utilisés/testés
- **[SLIDE 3]** Axe 2 - les réadmissions
 - Accroche : un enjeu humain et financier.
 - définition, taux de population touchée



- KPI : Taux de réadmission, focus sur le batch étudié : nombre d'hospitalisations et nombre de patients
- **[SLIDE 4]** Slide interactive sur l'évolution du taux de réadmission en fonction de différents facteurs:
 - Facteurs patientèle:
 - Ethnie
 - Tranche d'âge
 - Genre
 - Facteurs médicaux
 - Dosage d'Insuline
 - Nombre de médicaments prescrits
 - Nombre de changement de posologie
 - Facteurs hospitaliers
 - Durée du séjour
 - Nombre de visite(s) effectuée(s) (sous un an pré hospitalisation)
- **[SLIDE 5]** Présentation de l'évolution du taux de réadmission à travers un Line Chart selon 4 facteurs *sélectionnables* :
 - Durée du séjour
 - Nombre de médicaments
 - Total des visites
 - Changement de posologie
- **[SLIDE 6]** Introduction à nos résultats en Machine Learning et la perspective d'un modèle de prédiction des réadmissions avec vulgarisation des notions de précision et recall et présentation des taux True/False-Positive/Negative.
- **[SLIDE 7]** Présentation à travers un Donut Chart des différents facteurs influant sur le taux de réadmissions et leur taux d'importance/poids dans notre modèle de prédiction.
- **[SLIDE 8]** Première conclusion avec la présentation de quatre recommandations et l'introduction d'un objectif chiffré : la mise à niveau du taux de réadmission le plus haut établi pour notre patientèle la plus à risque au taux de réadmission moyen.
- **[SLIDE 9]** Présentation chiffrée et documentée de l'impact possible en cas de réalisation de l'objectif précédemment proposé à travers le nombre de réadmissions évitées et l'économie brute que cela pourrait représenter.



2. Modélisation - Power Query & DAX

SLIDE 1

→ Cette slide ne contient que des textbox de données non tirées de nos datasets.

SLIDE 2

→ 6 Measures ont été créés ici :

- Durée moyenne des séjours enregistrés

→ DAX :

```
AVG_Duree =  
AVERAGE ( hospitalisations[duree] )
```

→ Calcul de la moyenne de la colonne duree de la table hospitalisation.

- Moyenne du total des visites effectuées un an pré-hospitalisation

→ DAX :

```
AVG_total_visites_patient_id =  
AVERAGEX (  
    VALUES ( hospitalisations[patient_id] ),  
    CALCULATE (  
        SUM ( hospitalisations[n_visite_externe] )  
        + SUM  
        ( hospitalisations[n_visite_hopital] )  
        + SUM  
        ( hospitalisations[n_visite_urgence] )  
    )  
)
```

→ Calcule initialement le total pour chaque patient unique (utilisation de VALUES pour garantir l'unicité) de n_visite_externe + n_visite_urgence + n_visite_hopital de la table hospitalisation et calcule ensuite la moyenne de ce total en parcourant les entrées un patient_id à la fois (usage d'AVERAGEX)



- Moyenne du nombre de médicaments pris par patient

→ DAX :

```
AVG_total_medicaments_patient_id =  
AVERAGEX (   
    VALUES ( hospitalisations[patient_id] ),  
    CALCULATE ( SUM  
        ( hospitalisations[n_medicament] ) )  
    )
```

→ Calcule la moyenne pour chaque patient_id unique de la colonne n_medicament de la table hospitalisation.

- Tranche d'âge majoritaire

→ DAX :

```
TOP_Tranche_age =  
CALCULATE (   
    SELECTEDVALUE  
        ( hospitalisations[tranche_age] ),  
    TOPN (   
        1,  
        SUMMARIZE (   
            hospitalisations,  
            hospitalisations[tranche_age],  
            "Nb", COUNTROWS ( hospitalisations )  
        ),  
        [Nb], DESC  
    )  
    )
```

→ SUMMARIZE crée une table temporaire pour compter (Nb-COUNTROWS) le nombre d'hospitalisations¹¹ par tranche d'âge. Les résultats sont ordonnés de manière croissante (DESC) et seule la valeur en position 1 (TOPN(1)) est affichée.

- Ethnie majoritaire au sein de la patientèle

→ DAX :

¹¹ La tranche d'âge étant un paramètre amené à évoluer pour chaque patient_id, le calcul ici ne peut pas se faire en fonction de ce dernier.



```
TOP_ethnie =  
CALCULATE (  
    SELECTEDVALUE ( patients[ethnie] ),  
    TOPN (  
        1,  
        SUMMARIZE ( patients, patients[ethnie],  
            "Nb", COUNTROWS ( patients ) ),  
        [Nb], DESC  
    )  
)
```

→ Même principe que pour la tranche d'âge mais cette fois-ci dans la table patients et par rapport au nombre de patient_id (uniques dans la table dédiée).

- Genre majoritaire au sein de la patientèle

→ DAX :

```
TOP_genre =  
CALCULATE (  
    SELECTEDVALUE ( patients[genre] ),  
    TOPN (  
        1,  
        SUMMARIZE ( patients, patients[genre],  
            "Nb", COUNTROWS ( patients ) ),  
        [Nb], DESC  
    )  
)
```

→ Même principe que pour l'ethnie.

SLIDE 3

→ 3 Measures ont été créées ici

- Taux de réadmission sur l'ensemble des hospitalisations par patient unique

→ DAX :



```
%_Réadmis =  
DIVIDE (  
    CALCULATE (  
        DISTINCTCOUNT  
        ( hospitalisations[patient_id] ),  
        hospitalisations[readmis] = 1  
    ),  
    DISTINCTCOUNT ( hospitalisations[patient_id] )  
)
```

→ Division (DIVIDE) du nombre de patient_id uniques réadmis (CALCULATE compte les entrées où la condition est vraie, unicité garantie par l'usage de DISTINCTCOUNT, filtrage des réadmis via hospitalisations[readmis]=1) par le nombre de patient_id uniques.

- Nombre d'entrées dans la table de faits Hospitalisations

→ DAX :

```
distinct_hospi =  
DISTINCTCOUNT  
( hospitalisations[hospitalisation_id] )
```

→ Compte le nombre d'entrée dans la table hospitalisation via un DISTINCTCOUNT sur les hospitalisation_id. Plutôt qu'un COUNTROWS, cela permet de s'assurer de ne pas prendre en compte d'éventuels doublons (même si un nettoyage sur ce point précis a été effectué en amont).

- Nombre de patients uniques

→ DAX :

```
distinct_patients =  
DISTINCTCOUNT ( hospitalisations[patient_id] )
```

→ Même principe que pour le nombre d'hospitalisations.

SLIDE 4

→ 4 Measures, 1 set de Paramètres et 1 Colonne calculée ont été créées ici

- Taux de réadmission hospitalier (stacked bar chart)



Afin de compiler le taux de réadmission en fonction de différents facteurs dans un seul et même graphique (permettant d'alléger le slide), un set de paramètres a été créé :

```
Parameters_EGTD =  
{  
  ( "Ethnie", NAMEOF ( 'patients'[ethnie] ),  
0 ),  
  ( "Genre", NAMEOF ( 'patients'[genre] ), 1 ),  
  ( "Tranche d'age", NAMEOF  
( 'hospitalisations'[tranche_age] ), 2 ),  
  ( "Dosage Insuline", NAMEOF  
( 'hospitalisations'[insulin] ), 3 )  
}
```

→ Il reprend les colonnes ethnie et genre de la table patients, puis tranche_age et insuline de la table hospitalisations. Placé dans un slicer, il sera donc possible de sélectionner chaque critère et d'afficher le graphique correspondant, à savoir

- Taux de réadmission en fonction de l'ethnie,
- Taux de réadmission en fonction du genre,
- Taux de réadmission en fonction de la tranche d'âge,
- Taux de réadmission en fonction du dosage d'insuline

Pour chaque critère, un taux de représentation est calculé grâce à la mesure %_Représentation :

→ DAX :

```
%_Représentation =  
100  
* DIVIDE (  
  DISTINCTCOUNT  
( hospitalisations[hospitalisation_id] ),  
  CALCULATE (  
    DISTINCTCOUNT  
( hospitalisations[hospitalisation_id] ),  
    ALLSELECTED  
( hospitalisations[tranche_age] ),  
    ALLSELECTED ( patients[genre] ),  
    ALLSELECTED ( patients[ethnie] ),  
    ALLSELECTED  
( hospitalisations[insulin] )  
  )  
)
```



→ Calcule un taux de représentation au sein des hospitalisations de chaque valeurs uniques de chaque colonnes via la division (**DIVIDE**) du nombre d'hospitalisation unique (**DISTINCTCOUNT**) par le résultat du calcul suivant : le **CALCULATE** compte le nombre d'hospitalisation unique par tranches d'âge, genres, ethnies et dosage d'insuline; le **ALLSELECTED** permet de rendre ce calcul imperméable à la sélection faite dans le slicer : si l'utilisateur sélectionne à la fois Tranche_age et Genre, le taux calculé ici restera inchangé.

Des règles de colorisation ont également été ajoutées pour ce graphique en fonction de ce taux précédemment calculé :

Format style

Rules

What field should we base this on?

%_Représentation1

Rules

↕ Reverse color order

+ New rule

If value	>=	0	Percent	and	<	25	Percent	then		↑ ↓ ×
If value	>=	25	Percent	and	<	50	Percent	then		↑ ↓ ×
If value	>=	50	Percent	and	<	75	Percent	then		↑ ↓ ×
If value	>=	75	Percent	and	<=	100	Percent	then		↑ ↓ ×

D'autres facteurs sont également actionnables via 4 slicers en bas de page, trois font directement appel à des colonnes existantes : duree, n_changement_posologie et n_medicament, le dernier lui a nécessité la création d'une colonne calculée Total_Visites :

→ DAX :

```
Total_Visites =  
hospitalisations[n_visite_externe] +  
hospitalisations[n_visite_hopital] +  
hospitalisations[n_visite_urgence]
```

→ Cette colonne fait la somme des colonnes de la table hospitalisations suivantes : n_visite_externe + n_visite_hopital + n_visite_urgence et ce pour chaque entrée.



Il est donc ensuite possible d'observer la variation du taux de réadmission en fonction de ces différents facteurs, actionnables via les slicers et le stacked bar chart ; cette variation est visible grâce à une gauge paramétrée selon deux mesures :

- %_readmis_100 positionné en Value

→ DAX :

```
%_readmis_100 =  
100  
    * DIVIDE (  
        ( CALCULATE ( COUNTROWS ( hospitalisations  
        ), hospitalisations[readmis] = 1 ) ),  
        DISTINCTCOUNT  
        ( hospitalisations[hospitalisation_id] )  
    )
```

→ Calcule la division (DIVIDE) du nombre d'hospitalisations où le critère réadmis est égal à 1 (CALCULATE COUNTROWS) par le nombre d'hospitalisations uniques (DISTINCTCOUNT).

- %_Readmis_Moyen positionné en Target Value

→ DAX :

```
%_Readmis_Moyen =  
CALCULATE ( AVERAGE ( hospitalisations[readmis] ),  
ALL ( hospitalisations ) ) * 100
```

→ Calcule le taux de réadmission moyen de la colonne readmis en fonction de la totalité des hospitalisations.


Pour plus de lisibilité, une mesure supplémentaire a été ajoutée et insérée dans une Card afin de calculer le nombre de patients concernés en fonction des critères sélectionnés, Nb_Patients_Selection :

→ DAX :

```
Nb_Patients_Sélection =  
"soit " & FORMAT ( DISTINCTCOUNT  
    ( hospitalisations[patient_id] ), "#,##0" ) & "  
patient(s)"
```




→ Affiche le nombre de patients uniques (DISTINCTCOUNT) selon le format séparation des milliers par une virgule “,” et deux décimales post virgule “##”. Les “&” permettant le lien entre un format “text” et l’utilisation d’une formule.



→ 1 Measure, 2 colonnes calculées et 1 set de Paramètres ont été créées ici

Un Line Chart a été créé afin de visualiser l’évolution du taux de réadmission en fonction de quatre critères spécifiques.

Pour des raisons de lisibilité, deux colonnes calculées ont été créée afin de grouper les valeurs hautes ne concernant qu’un faible nombre de patients sur le principe suivant :

Toute valeur supérieure à X sera égale à X, est conservée si inférieure.

N_MED_MAX fixe donc à 50 médicaments le seuil au delà duquel les valeurs sont regroupées :

→ DAX :

```
N_MED_MAX =  
IF ( hospitalisations[n_medicament] > 50, 50,  
hospitalisations[n_medicament] )
```

→ Pose la condition suivante : si la valeur n_medicament de la table hospitalisations est supérieure à 50, alors l’entrée correspondante dans la colonne N_MED_MAX égale à 50 sinon la colonne N_MED_MAX égale la valeur n_medicament correspondante.

Même principe avec TVPP_MAX qui fixe donc à 30 visites le seuil au delà duquel les valeurs sont regroupées :

→ DAX :

```
TVPP_MAX =  
IF ( [Total_Visites_par_Patient] > 30, 30,  
[Total_Visites_par_Patient] )
```

→ Pose la condition suivante : si la valeur Total_Visites_par_Patient de la table hospitalisations est supérieure à 30, alors l’entrée correspondante dans la colonne TVPP_MAX égale à 30 sinon la



colonne TVPP_MAX égale la valeur Total_Visites_par_Patient correspondante.

Comme pour le Staked Bar Chart en Slide 4, le même principe a été repris et un nouveau set de paramètres a été créé :

→ DAX :

```
Parameter_Lines =  
{  
    ( "Durée du Séjour", NAMEOF  
    ( 'hospitalisations'[duree] ), 0 ),  
    ( "Total Visites", NAMEOF  
    ( hospitalisations[TVPP_MAX] ), 1 ),  
    ( "Nbre Médicaments prescrits", NAMEOF  
    ( 'hospitalisations'[N_MED_MAX] ), 2 ),  
    ( "Nbre de changement de posologie", NAMEOF  
    ( 'hospitalisations'[n_changement_posologie] ),  
    3 )  
}
```

→ Il reprend les colonnes duree et n_changement_posologie de la table hospitalisation et les deux colonnes calculées précédemment : N_MED_MAX et TVPP_MAX également dans cette même table. Placé dans un slicer, il sera donc possible de sélectionner chaque critère et d'afficher le graphique correspondant, à savoir l'évolution du :

- Taux de réadmission en fonction de la durée du séjour,
- Taux de réadmission en fonction du total de visites,
- Taux de réadmission en fonction du nombre de médicament(s) prescrit(s),
- Taux de réadmission en fonction du nombre de changement de posologie.

Ces paramètres sont utilisés sur l'axe X de notre Line Chart, en axe Y est repris la mesure %_readmis_100 précédemment détaillée.

Afin d'afficher visuellement le nombre de patient concerné sur le graphique, un code couleur a été établi via Markers, le tout en fonction de la mesure créée N_Patients_Selection_2, intégrée en Tooltips.



Format style

Rules

What field should we base this on?

N_Patients_Selection_2

Rules

↕ Reverse color order

+ New rule

If value	>=	0	Number	and	<	5000	Number	then		↑ ↓ ×
If value	>=	5000	Number	and	<	10000	Number	then		↑ ↓ ×
If value	>=	10000	Number	and	<	20000	Number	then		↑ ↓ ×
If value	>=	20000	Number	and	<=	100	Percent	then		↑ ↓ ×

→ DAX :

```
N_Patients_Selection_2 =  
DISTINCTCOUNT ( hospitalisations[patient_id] )
```

→ Compte le nombre d'hospitalisation_id uniques (DISTINCTCOUNT) en fonction du critère sélectionné sur le slicer.

Une courbe de tendance et une ligne indiquant la moyenne ont également été ajoutées. Enfin une dernière mesure a été créé afin d'afficher la moyenne sur le total des hospitalisations pour chaque critères du paramètre créé : Moyenne_Selection.

→ DAX :



```
Moyenne_Sélection =  
SWITCH (  
    SELECTEDVALUE  
    ( Parameter_Lines[Parameter_Lines Order] ),  
    0, AVERAGE ( hospitalisations[duree] ),  
    1, AVERAGE  
    ( hospitalisations[Total_Visites] ),  
    2, AVERAGE ( hospitalisations[n_medicament] ),  
    3, AVERAGE  
    ( hospitalisations[n_changement_posologie] ),  
    BLANK ()  
)
```

→ Calcule et affiche la moyenne en fonction du nombre d'hospitalisations pour les critères sélectionnés de la table hospitalisations. Si rien n'est sélectionné (BLANK) dans le slicer, aucune valeur n'est affichée.

SLIDE 6

→ 8 Measures ont été créées ici

Afin de mettre en avant notre étude sur les modèles de prédiction de façon à ce qu'elle soit compréhensible par un public non averti, nous avons mis en place un visuel sous forme de matrice ainsi que deux gauges grâce à la création de 9 mesures.

La matrice centrale affiche des taux calculés à partir de la table RFC_confusion_matrix, initialement importée sous cette forme :

Prediction_0	Prediction_1
45541	24958
3842	5284

Via l'interface Transform Data de Power Bi, nous avons transformé cette table via l'ajout d'une colonne Index et l'usage de la fonction Unpivot, pour le résultat suivant :



Réalité	Prediction	Value
0	0	45541
0	1	24958
1	0	3842
1	1	5284

Cette table est traduisible ainsi :

Cas	Measure Correspondant	Value	Interprétation
Vrai - Négatif	TN	45541	✅ Patients sans risque, correctement écartés
Faux - Positif	FP	24958	🔔 Fausses alertes
Faux - Négatif	FN	3842	⚠️ Patients à risque manqués
Vrai - Positif	TP	5284	✅ Patients à risque détectés

Les quatres mesures ici TN, FP, FN, TP reprennent simplement la Value correspondante via l'usage de la formule DAX suivante :

→ DAX :

```
TN =  
CALCULATE (  
    SUM ( RFC_confusion_matrix[Value] ),  
    RFC_confusion_matrix[Réalité] = 0,  
    RFC_confusion_matrix[Prediction] = 0  
)
```

A été calculé ensuite un taux pour chacune des quatre mesures TN, FP, FN, TP sur le même modèle :

→ DAX :

```
FP_% =  
DIVIDE ( [FP], [TP] + [FN] + [FP] + [TN] )
```



→ Calcul de la division (DIVIDE) de la Value (ici [FP]) par la somme des quatre valeurs [FN] + [TN] + [TP] + [FP].

Ce sont ces taux XX_% qui sont repris dans la matrice.

Les gauges reprennent ensuite le score de recall et precision de nos modèles, à savoir :

- Le taux de détection des patients à risque : le **recall**
- Le taux d'alertes justifiées : la **precision**

La table RFC_metrics a été utilisée ici et a été transformée via Transform Data simplement avec l'ajout d'une colonne d'index, 0 et 1 plutôt que de travailler avec le numéro de ligne, sachant que seul l'index 1 nous intéresse dans notre présentation puisqu'il correspond à la performance du modèle sur la classe "réadmis à <30 jours".

On est donc passé de :

precision	recall	f1-score	support	roc-auto
0.92219994735030275	0.64598079405381637	0.75976376770490983	70499.0	0.64893301138305148
0.17472389392235962	0.5790050405435021	0.26844137370453158	9126.0	0.64893301138305148

À

index	precision	recall	f1-score	support	roc-auto
0	0.92219994735030275	0.64598079405381637	0.75976376770490983	70499.0	0.64893301138305148
1	0.17472389392235962	0.5790050405435021	0.26844137370453158	9126.0	0.64893301138305148

Sachant que nous avons donc fait le choix de ne pas présenter les 3 autres scores une nouvelle fois par souci de compréhension de la part de notre audience.



Deux mesures ont donc été créées et utilisées dans chacune des gauges, chacune calculant le taux de recall et précision pour l'index 1 déjà présent dans la table via un simple produit par 100 :

→ DAX :

```
Recall_Risque_1 =  
CALCULATE ( SELECTEDVALUE ( RFC_metrics[recall] ),  
RFC_metrics[Index] = 1 ) * 100
```

Chacune des gauges est ensuite explicitée grâce à une phrase “Bilan” sur le même modèle et avec la même intention que la première, à savoir :

Bilan_recall :

→ DAX :

```
Bilan_Recall =  
"Sur 100 patients qui seront réadmis, le modèle en  
identifie "  
& FORMAT ( [Recall_Risque_1], "0" ) & "."
```

Bilan_precision :

→ DAX :

```
Bilan_Precision =  
"Sur 100 alertes émises, " & FORMAT  
( [Precision_Risque_1], "0" ) & " concernent de  
vrais patients à risque."
```

SLIDE 7

→ 1 Measure et 1 colonne calculée ont été créées ici

Ce slide reprend les différents facteurs (les features) pouvant peser/ influencer dans la prédiction de la réadmission. Le tout a été présenté sous forme de Donut Chart avec les différents taux d'importance de chaque facteur.

Afin de clarifier la légende dans des termes simples et compréhensibles, une colonne calculée Facteurs a été créée pour “traduire” nos termes techniques en se reposant sur le DAX suivant :



```
Facteurs =
IF (
    RFC_features_importance[feature] =
"score_visite",
    "Score de visite",
    IF (
        RFC_features_importance[feature] =
"categorie_sortie_Home",
        "Retour au domicile",
        IF (
            RFC_features_importance[feature] =
"categorie_sortie_Care Facility",
            "Transfert vers Maison de Repos",
            IF (
                RFC_features_importance[feature] =
"n_diag_max_9",
                "Nombre de diagnostics",
                IF (
                    RFC_features_importance[feature] =
"categorie_diag_3_Follow-up/Rehabilitation",
                    "Suivi / Rééducation",
                    IF (
                        RFC_features_importance[feature] =
"categorie_sortie_Hospital",
                        "Transfert vers un
hopital",
                        IF (
                            RFC_features_importance[feature] =
"categorie_diag_1_Neoplasms/Cancer",
                            "Cancer primo-
diagnostiqué",
                            IF (
                                RFC_features_importance[feature] =
"categorie_specialite_Oncology",
                                "Consultation
d'Oncologie",
                                "Cancer
diagnostiqué"
                            )
                        )
                    )
                )
            )
        )
    )
)
```





→ Chaque ligne est interrogée sur le même modèle à savoir “Si cette cellule contient la valeur xxx alors xxxx” (IF, l’utilisation d’une première “,” correspondant à un THEN, puis la seconde “,” à un ELSE)

Le taux d’importance lui est calculé via la mesure du même nom, avec le DAX suivant :

→ DAX :

```
%_Importance =  
RFC_features_importance[importance] * 100
```



→ 1 Measure a été créée ici

Ce premier slide de conclusion reprends quelques une de nos recommandations à la suite de notre étude et fixe un objectif chiffré, celui de faire baisser le taux de réadmission de notre patientèle définie comme la plus à risque et de faire revenir ce taux au taux de réadmission calculé sur l’ensemble de notre batch calculé via la mesure %_Readmis déjà explicité;

Afin d’identifier et calculer le taux de réadmission de notre patientèle définie comme la plus à risque, il a premièrement été nécessaire de définir cette patientèle.

Nous avons donc défini les critères suivants :

→ Consultation d’un Oncologue (specialite_id 27)
ET Diagnostiqué d’un Cancer (icd9_id entre 140 et 239)

OU

→ Un total de visite (n_visite_externe+n_visite_hopital+n_visite_urgence)
supérieur à 5

La mesure %_Réad_Groupe_Risque a donc été créée et placée dans une card.

→ DAX :



```
%_Réad_Groupe_Risque =  
VAR GroupeR =  
  FILTER (  
    hospitalisations,  
    (  
      hospitalisations[specialite_id] = 27  
      && CALCULATE (  
        COUNTROWS (  
          FILTER (  
            diagnostiques,  
            VALUE  
            ( diagnostiques[icd9_id] ) ≥ 140  
            && VALUE  
            ( diagnostiques[icd9_id] ) ≤ 239  
          )  
        )  
      ) > 0  
    )  
    ||  
    ( hospitalisations[n_visite_externe] +  
      hospitalisations[n_visite_urgence] +  
      hospitalisations[n_visite_hopital] ≥ 5 )  
  )  
RETURN  
  DIVIDE ( SUMX ( GroupeR,  
    hospitalisations[readmis] ), COUNTROWS ( GroupeR )  
  )
```

→ Une variable **GroupeR** a été déclarée (VAR) en fonction des critères précédemment définis; **GroupeR** regroupe donc l'intégralité des hospitalisations qui répondent à un ou aux deux groupes de critères définis. Est retourné ensuite (RETURN) le résultat de la division (DIVIDE) du nombre de réadmissions par le nombre total de lignes de ce groupe.

SLIDE 9

→ 1 set de paramètre et 2 mesures ont été créés ici

Ce dernier slide de conclusion a pour but de présenter d'un point de vue économique ce que pourrait représenter une baisse du taux d'admission dans l'exemple précis de notre objectif chiffré.

Le but étant de permettre via un slicer de faire baisser ce taux de réadmission et de mettre à jour en temps réel une phrase type bilan présentant de manière chiffrée les économies brutes possibles.



Pour créer ce slicer, il a fallu définir un set de paramètres cette fois chiffré comme tel :

```
Tx_Read_GR =  
VAR Cible = [%_Réadmis] * 100  
VAR Base = [%_Réad_Groupe_Risque] * 100  
RETURN  
    GENERATESERIES ( Cible, Base, 0.01 )
```

Ce paramètre définit les limites de notre slicer :

- Un MIN à 12.35 (le taux de réadmission **Cible**)
- Un MAX à 23.26 (le taux de réadmission de départ, **Base**)
- Un pas de 0,01 (pour permettre de changer ce taux de manière précise)

Dans une card est placé la mesure suivante, renvoyant le taux sélectionné dans le slicer :

→ DAX :

```
Tx_Read_GR Value =  
SELECTEDVALUE ( Tx_Read_GR[Tx_Read_GR], 23.26 )
```

La colorisation de la card est définie selon les valeurs sélectionnées :

Format style

Gradient

What field should we base this on?

Tx_Read_GR Value

How should we format empty values?

As zero

Minimum

Custom

12,35

Maximum

Custom

23,26

☐ Add a middle color





Enfin, la dernière mesure de notre dashboard est donc notre phrase bilan, calculant et présentant les possibles économies en cas de baisse du taux de réadmission dans notre groupe à risque.

La mesure Hospi_evitees repose sur le DAX suivant :

→ DAX :

```
Hospi_evitees =  
VAR Tx_R_GR = [%_Réad_Groupe_Risque]  
VAR Nb_hospi_GR = [Nb_Hospit_Groupe_Risque]  
VAR Tx_Modifiable = [Tx_Read_GR Value]  
VAR Eco = 214012  
VAR Produit_Tx_Nb = Nb_hospi_GR * Tx_R_GR  
VAR Avoided_rea =  
    Produit_Tx_Nb - ( DIVIDE ( Tx_Modifiable ,  
100 ) * Nb_hospi_GR )  
VAR Avoided_rea_10ans =  
    Produit_Tx_Nb - ( DIVIDE ( Tx_Modifiable ,  
100 ) * Nb_hospi_GR )  
VAR Avoided_rea_annuel =  
    ROUND ( DIVIDE ( Avoided_rea_10ans , 10 ) , 0 )  
VAR Eco_annuelle = Avoided_rea_annuel * Eco  
RETURN  
    "soit " & Avoided_rea_annuel & "  
réadmission(s) évitée(s) par an sur le panel le  
plus à risque, équivalent à une économie brute  
annuelle de ~"  
    & FORMAT ( Eco_annuelle , "#,0 $" ) & "★"
```

→ Plusieurs variable sont déclarées :

→ Tx_R_GR : Taux de réadmission dans notre groupe à risque

→ Nb_hospi_GR : Nombre d'hospitalisations total dans notre groupe à risque

→ Tx_Modifiable : Valeur du taux manipulable via slicer

→ Eco : économie estimée en dollars d'une réadmission sous 30 jours évitée

¹² Coût variable moyen évité par réadmission à 30j évitée, tous cas confondus - Health Care Management Science, VA study 2015



→ **Produit_Tx_Nb** : Nombre d'hospitalisations concernées par une réadmission calculée en fonction du taux de réadmission dans notre groupe à risque

→ **Avoided_rea_10ans** : Calcul sur 10 ans (nos données couvrant 10 années d'hospitalisations) du nombre d'hospitalisation potentiellement évitables via la soustraction du nombre d'hospitalisations concernées par une réadmission par le résultat du produit de la division du taux modifiable par 100 x le nombre d'hospitalisations total dans notre groupe à risque

→ **Avoided_rea_annuel** : Calcul l'**Avoided_rea_10ans** sur une seule année via la division de cette dernière par 10.

→ **Eco_annuelle** : Calcul des économies possibles via le produit du nombre de réadmissions évitables par an x l'économie estimée en dollars d'une réadmission sous 30 jours évitée

Avoided_rea_annuel et **Eco_annuelle** sont ensuite intégrés dans notre phrase bilan.

Le fichier original est consultable [ici](#).

Le fichier pdf du dashboard est consultable [ici](#).



H. CONCLUSION

1. Enseignements et recommandations

Ce projet a permis de construire une chaîne de traitement complète, de la donnée brute (pour rappel, plus de 100.000 hospitalisations répertoriées sur 130 hôpitaux américains, de 1999-2008) jusqu'à des recommandations actionnables, en s'appuyant sur un pipeline dbt/BigQuery puis sur une modélisation Python le tout restitué dans un rapport Power BI.

L'analyse a montré qu'un nombre très restreint de features (9 sur 115) suffit à obtenir des performances comparables à celles d'un modèle utilisant l'ensemble des variables : catégories de diagnostics (cancer, suivi/rééducation), type de sortie d'hospitalisation, spécialité oncologie, nombre de diagnostics maximal et score de visite. Parmi ces variables, seule la sortie vers le domicile ("Home") est associée à une non-réadmission.

Ce constat doit toutefois être nuancé : la plupart de ces features reflètent davantage un état de santé global qu'une cause isolée de réadmission. Un patient globalement en bonne santé, hospitalisé pour une raison mineure, cumule naturellement peu de diagnostics, un score de visite faible, et rentre chez lui — trois signaux qui se répondent sans lien de causalité direct entre eux. À l'inverse, un patient chronique avec de lourdes complications présente logiquement un score de visite et un nombre de diagnostics élevés, et le profil oncologie - si présent - implique un suivi spécialisé peu compatible avec un retour à domicile. Le modèle capture donc surtout des profils de gravité globale, plus que des leviers d'action isolés.

→ Des performances prédictives à nuancer selon les sous-populations

Les modèles prédictifs affichent des performances globales décevantes (rappel ~58 %, précision ~17 %) : la majorité des réadmissions potentielles sont détectées, mais au prix d'un grand nombre de faux positifs (1 alertes sur 6 avérées), ce qui rendrait un suivi intensif généralisé aux patients signalés coûteux et peu soutenable. Cette performance globale masque cependant des disparités : le modèle est nettement plus performant sur la tranche d'âge 20-30 ans, vraisemblablement parce que les réadmissions y sont plus homogènes (probablement liées au cancer), malgré le faible volume d'hospitalisations dans cette catégorie.

Ces limites s'expliquent en partie par la nature même du phénomène : la réadmission est un événement rare et multi-factoriel, dépendant aussi de facteurs socioéconomiques, comportementaux et environnementaux non présents dans le jeu de données.



→ Recommandations opérationnelles

En croisant clustering et modèle prédictif, une approche de prévention à deux niveaux peut être proposée :

- Suivi intensif pour les hospitalisations à risque élevé et celles signalées par le modèle : prolongation de quelques jours d'observation pour stabiliser l'état du patient, suivi téléphonique hebdomadaire, avec un objectif de ramener le taux de réadmission vers la moyenne.
- Suivi adapté pour les hospitalisations à risque modéré : appel de suivi dans la semaine suivant la sortie, proposition de téléconsultation.

Le seuil de décision du modèle devrait par ailleurs être ajusté en fonction du coût réel d'une fausse alerte comparé à celui d'une réadmission manquée, plutôt que sur un seuil par défaut.

Enfin, le nombre de médicaments prescrits et les changements de posologie apparaissent associés au risque de réadmission, ce qui suggère deux leviers concrets : limiter les modifications de traitement sans indication clinique claire, et renforcer la formation des patients diabétiques à l'auto-médication pour réduire les risques de sur- ou sous-dosage.

→ Limites et perspectives

Les performances actuelles restent contraintes par la richesse limitée du jeu de données. Leur amélioration passerait par l'enrichissement des données disponibles : contexte socio-professionnel et localisation géographique, historique médical complet, dates précises du séjour, détail des médicaments administrés pendant l'hospitalisation et de leurs changements de posologie. Comme indiqué précédemment, la conservation de la donnée `payer_code` nous aurait également permis d'enrichir notre étude.

2. Gestion du projet, limites et perspectives d'améliorations

Une des principales limites à laquelle nous avons été confrontés vient d'être évoquée, la relative pauvreté du jeu de données. Enrichi, ce dernier aurait permis une étude plus poussée et possiblement de meilleurs résultats dans nos modèles.

Toutefois, sa relative bonne tenue et notamment l'absence de données aberrantes ou de formatage complexe nous a grandement facilité la tâche, d'autant que nous avons pris certaines décisions nous permettant de ne pas nous confronter à ce genre de problématique (non usage de la colonne `payer_code` notamment ou non



reformage de la colonne `tranche_age`). Si bien que nous avons probablement un peu trop occulté la gestion des erreurs et c'est en soi une des pistes possibles d'améliorations de notre projet data.

La partie orchestration a également souffert en raison des limites imposées par airbyte; notre automatisation du pipeline n'est pas au point et serait donc à revoir.


Enfin côté collaboration, une communication claire et une bonne gestion du temps nous on permis d'avancer à un rythme soutenu, également grâce à l'excellent bagage technique d'Audric sans qui une bonne partie de cette étude ne serait pas si aboutie.

La création du dashboard s'est avérée *nécessairement* chronophage et a permis un léger ré-équilibre dans le travail produit bien que nous ayons tout deux activement travaillé conjointement sur l'ensemble du projet sans délégation.

3. Remerciements

Un grand merci à **Audric** pour sa collaboration et son aide,

Et aux équipes de La Capsule, particulièrement **Clovis Battelo** et **Raida Rehouni** pour leur soutien tout au long de notre formation et de notre projet.





Annexe – Récapitulatif

Modèle en étoile : fact_hospitalisations au centre, entouré des dimensions. Table de jonction jonction_diagnostiques pour la relation many-to-many avec dim_icd9.

A. fact_hospitalisations

Granularité : Une ligne = une hospitalisation.

Colonne	Type	Description	Notes
hospitalisation_id	INT	Clé primaire	
patient_id	INT	FK → dim_patients	
type_admission_id	INT	FK → dim_types_admissions	
source_admission_id	INT	FK → dim_sources_admissions	
sortie_id	INT	FK → dim_sorties	
specialite_id	INT	FK → dim_specialites_medicales	
tranche_age	VAR	Tranche d'âge du patient à cette hospitalisation	Peut varier d'une hospitalisation à l'autre pour un même patient – non rattachable à un patient unique
duree	INT	Durée du séjour (jours)	
n_test_lab	NUM	Nombre de tests de laboratoire	
n_procedure	NUM	Nombre de procédures effectuées	



Colonne	Type	Description	Notes
n_medicament	NUM	Nombre de médicaments prescrits	Plafonné à 50 pour la visualisation PBI
n_visite_urgence	INT	Visites aux urgences dans l'année précédente	
n_visite_hopital	INT	Visites hospitalières dans l'année précédente	Meilleur prédicteur individuel identifié
n_visite_externe	INT	Visites externes dans l'année précédente	
n_diag	INT	Nombre de diagnostics posés durant le séjour	
insulin	VAR	Évolution du dosage d'insuline	Up/Down/Steady/No – traduit en FR dans les marts (non repris dans dbt_shared)
n_changement_posologie	INT	Nombre de médicaments (sur ~21) dont le dosage a changé (Up/Down)	
readmis	BOO	Variable cible : 1 si réadmis <30j, 0 sinon (>30j ou pas de réadmission)	

Colonnes de la source volontairement écartées :

- **weight** — 97% de valeurs manquantes
- **payer_code** — 52% de valeurs manquantes
- **A1Cresult** — présente dans la source mais exclue par choix méthodologique (facteur déjà documenté par la littérature)
- Colonnes médicaments
- **change** : non conservée au profit de **n_changement_posologie**



B. dim_patients

Une ligne = un patient unique (SELECT DISTINCT sur patient_id).

Colonne	Type	Description	Notes
patient_id	INT	Clé primaire	
ethnie	VAR	Ethnie déclarée	'?' si plusieurs valeurs différentes selon les hospitalisations du même patient
genre	VAR	Genre déclaré	Même règle de résolution que ethnie

C. dim_types_admissions

Colonne	Type	Description	Notes
type_admission_id	INT	Clé primaire	Codes source 5/6/8 fusionnés sous 5 ; code 7 remappé en 6
description	VAR	Libellé du type d'admission	Libellés ambigus ("Not Available", "NULL", "Not Mapped") normalisés en "Unknown"
categorie	VAR	Catégorie	



D. dim_sorties

Colonne	Type	Description	Notes
sortie_id	INT	Clé primaire	
description	VAR	Libellé du mode de sortie	Seule modalité corrélée à une non-réadmission : “Home”
categorie	VAR	Catégorie	

E. dim_sources_admissions

Colonne	Type	Description	Notes
source_admission_id	INT	Clé primaire	Code source 15 fusionné avec 9 (libellé identique, deux ids distincts à l’origine)
description	VAR	Libellé de l’origine de l’admission	
categorie	VAR	Catégorie	



F. dim_specialites_medicales

Colonne	Type	Description	Notes
specialite_id	INT	Clé primaire	Clé artificielle générée via ROW_NUMBER() OVER (ORDER BY original_speciality) — pas d'identifiant natif dans la source
specialite	VAR	Nom de la spécialité médicale	
description	VAR	Description	

G. dim_icd9

Colonne	Type	Description	Notes
icd9_id	INT	Clé primaire	Table de référence indépendante
description	VAR	Description du diagnostic	Codes ICD-9
categorie	VAR	Catégorie du diagnostic	Ex : “Neoplasms/ Cancer”, “Follow-up/ Rehabilitation”

H. jonction_diagnostiques (table de liaison)

Une ligne = un couple (hospitalisation, diagnostic). Résout la relation many-to-many entre une hospitalisation (jusqu'à 3 diagnostics : **diag_1**, **diag_2**, **diag_3**) et **dim_icd9**.



Colonne	Type	Description	Notes
hospitalisation_id	INT	FK → fact_hospitalisations	
icd9_id	INT	FK → dim_icd9	Construit par unpivot (3x SELECT en UNION ALL), diagnostics nuls exclus

I. Variable cible – logique de construction

readmitted (source, 3 valeurs <30 / >30 / NO) → **readmis** (booléen strict) :

- **readmis** = true si readmitted = '<30'
- **readmis** = false si readmitted ∈ {>30, NO}

J. Features retenues pour le modèle prédictif final (9 sur 115)

Feature	Origine
categorie_diag_1_Neoplasms/Cancer	dim_icd9 (1er diagnostic)
categorie_diag_2_Neoplasms/Cancer	dim_icd9 (2e diagnostic)
categorie_diag_3_Follow-up/ Rehabilitation	dim_icd9 (3e diagnostic)
categorie_sortie_Care Facility	dim_sorties
categorie_sortie_Hospital	dim_sorties
categorie_sortie_Home	dim_sorties – seule modalité associée à une non-réadmission
categorie_specialite_Oncology	dim_specialites_medicales
n_diag_max_9	fact_hospitalisations (plafonné)
score_visite	Calculé – score 0-10 pondérant les visites antérieures (feature engineering, pondération forte sur n_visite_hopital)